

UNIVERSIDAD NACIONAL DE INGENIERIA

REDES NEURONALES · MIA-203 · EXAMEN FINAL

Detección de enfermedades de la papa con aprendizaje profundo: comparación de ResNet-50 y Vision Transformer con imágenes de campo

Auditoría del dataset, ablación del preentrenamiento, Grad-CAM y una app web con el modelo final

Gabriel Ángel Nizama Duque
Martín Alexis Valdiviezo Palma
Juan José Pino Reyes
César Luis Jiménez Miranda

EQUIPO 4 / SECCIÓN A / NOVIEMBRE DE 2026

MAESTRÍA EN INTELIGENCIA ARTIFICIAL / UNIDAD DE POSGRADO FIIS

GITHUB.COM/GABO2607/PAPA-CNN-VS-VIT · AGROTEC-PAPA.VERCEL.APP

El problema: diagnosticar la papa con fotos de campo

La rancha, las virosis y las plagas reducen la cosecha si no se detectan a tiempo, y el diagnóstico depende de especialistas que no siempre llegan al campo. Un clasificador de fotos en el celular puede servir de **alerta temprana**.


Bacteria


Hongos


Sana


Nematodos


Plaga


Phytophthora


Virus

3,076
fotos tomadas en campo (Java Central, Indonesia)

7
clases: 6 problemas + hoja sana

11×
desbalance: hongos 740 frente a nematodos 67

0.68–0.74
exactitud publicada en este dataset (Shabrina et al., 2024)

Pregunta de investigación y contribuciones

¿CNN o Vision Transformer con pocos datos?

Con solo **~2,100 fotos de entrenamiento** y 7 clases desbalanceadas, ¿rinde mejor una CNN (**ResNet-50**) o un Transformer (**ViT-S/16**)? ¿Y cuánto depende el resultado del **preentrenamiento en ImageNet**?

¿Por qué aprendizaje profundo?

Los síntomas cambian de forma, color y tamaño, y las fotos traen fondos variados. Un Random Forest con descriptores manuales de color y textura llega solo a **0.464** de macro-F1.

¿Por qué no es obvio?

El ViT supera a las CNN cuando hay millones de imágenes, pero no tiene el sesgo de **localidad** de la convolución: con pocos datos podría fallar.

CONTRIBUCIONES

01 **Auditoría del dataset público:** 55 pares de fotos duplicadas, 6 con etiquetas contradictorias, y partición por grupos sin fuga.

02 **Comparación controlada:** 6 configuraciones × 3 semillas, macro-F1 y prueba de McNemar.

03 **Ablación del preentrenamiento:** aporta +0.355 de macro-F1 al ViT y +0.201 a la ResNet.

04 **Interpretabilidad y despliegue:** Grad-CAM con medida de concentración, y una app web que corre el modelo final en el celular.

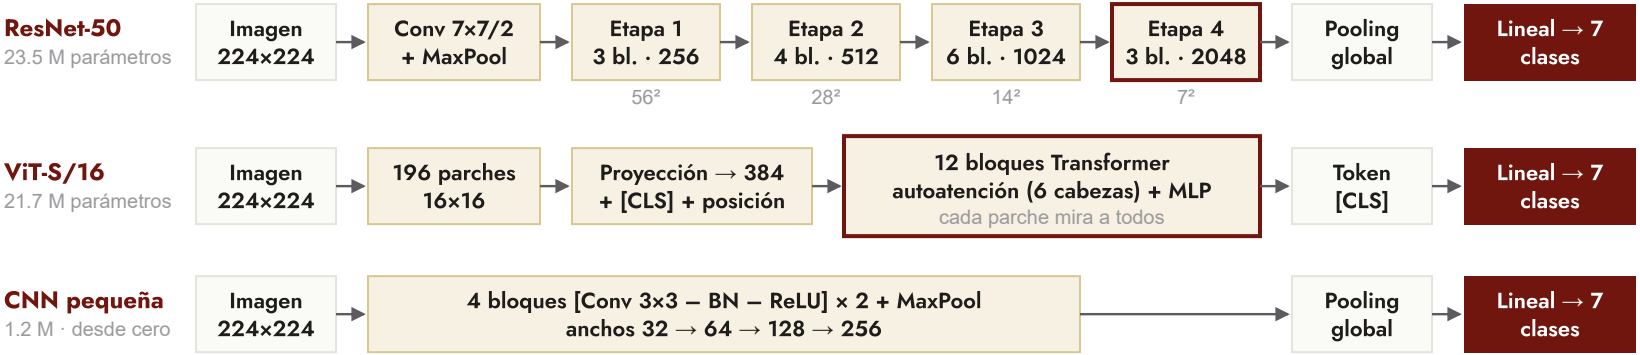
Trabajos relacionados

TRABAJO	QUÉ HACE	QUÉ HACEMOS DISTINTO
He et al., 2016 · ResNet	Conexiones residuales: permiten entrenar CNN muy profundas	Es nuestra CNN de referencia
Dosovitskiy et al., 2021 · ViT	Transformer sobre parches de 16×16; supera a las CNN con muchos datos	Lo probamos con ~2,100 fotos de campo
Touvron 2021; Steiner 2022	La regularización y el preentrenamiento compensan la falta de datos del ViT	Lo medimos con una ablación controlada
Mohanty 2016; Ferentinos 2018	Más de 99 % en PlantVillage (fotos de laboratorio); advierten que cae en campo	Usamos solo fotos de campo
Shabrina et al., 2024	**Publican el dataset; ResNet-50 0.682 y EfficientNetV2-B3 0.736 de exactitud, 1 corrida**	**Deduplicamos, 3 semillas, comparamos con ViT**
Selvaraju 2017 · Grad-CAM	Mapas de las regiones que deciden la clase	Añadimos una medida de concentración
Geirhos et al., 2020	Aprendizaje por atajos: decidir por pistas espurias del fondo	Lo detectamos en la CNN pequeña

El artículo cita 21 referencias, verificadas en Crossref. Ninguno de los trabajos sobre papa controla duplicados entre particiones, reporta varias semillas ni compara con Transformers.

Dos formas de mirar una imagen: convolución y autoatención

borde granate = capa donde se calcula Grad-CAM



CNN: localidad

Filtros pequeños que recorren la imagen; cada bloque aprende un residuo:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}$$

Sabe desde el inicio que los píxeles vecinos se relacionan.

ViT: atención global

Cada parche se relaciona con todos los demás desde la primera capa:

$$\mathrm{Att}(Q,K,V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_h}}\right)V$$

Más flexible, pero debe **aprender** la localidad de los datos.

Pesos preentrenados (timm)

ResNet-50: resnet50.a1_in1k
ViT-S/16: augreg_in21k_ft_in1k
Cambiamos la cabeza a 7 clases y ajustamos **todos** los parámetros.

Datos: auditoría del dataset y partición sin fuga

110
fotos en 55 pares de duplicados exactos (sha256)

12
fotos con **etiqueta contradictoria**: la misma foto en dos clases

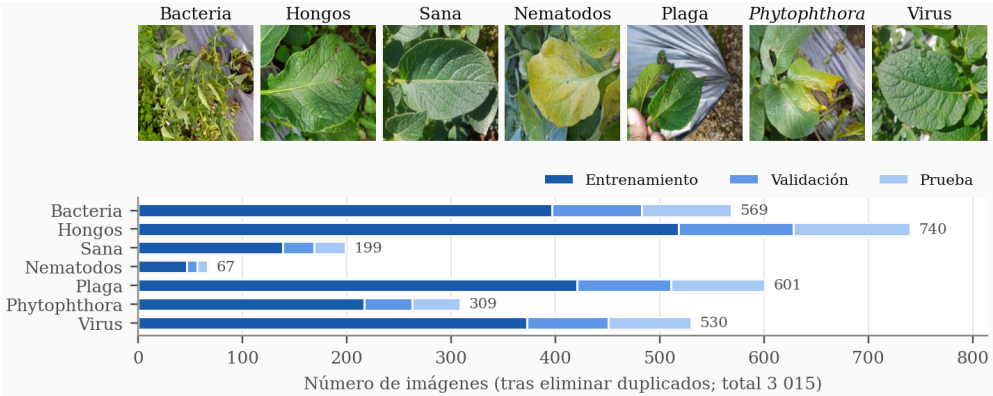
64
fotos en 32 grupos de casi-duplicados (dHash ≤ 4)

3,015
fotos finales, tras eliminar 12 contradictorias y 49 copias

PARTICIÓN 70/15/15	FOTOS	USO
Entrenamiento	2,112	aprender
Validación	450	elegir época y modelo
Prueba	**453**	**medir una sola vez**

Sin fuga de datos

Partimos **por grupos**: las fotos casi idénticas caen juntas en una sola partición. Verificado: **0** grupos, sha256 o dHash repetidos entre particiones.



Pista para después: 5 de los 6 pares contradictorios involucran a **plaga**, y 3 son exactamente **hongos / plaga**.

Metodología: pérdida y entrenamiento

Entropía cruzada ponderada (contra el desbalance)

$$\mathcal{L} = -\frac{\sum_i w_{y_i} \log p_{i,y_i}}{\sum_i w_{y_i}}, \qquad w_k = \frac{1/n_k}{\frac{1}{K}\sum_j 1/n_j}$$

Las clases raras pesan más: **nematodos 3.5**, hongos 0.32.

Optimización

AdamW, lote 32, **40 épocas**, *warmup* de 2 épocas y luego decaimiento coseno; recorte de gradiente a norma 1; precisión mixta (fp16) en ResNet y ViT.

Aumento de datos

Recorte aleatorio (escala 0.6–1), volteos, rotación ±20° y variación de brillo, contraste, saturación y tono.

MODELO	LR PRE / CERO	WEIGHT DECAY	PARÁMETROS
CNN pequeña	— / 10^{-3}	0.01	1.2 M
ResNet-50	3×10^{-4} / 10^{-3}	0.05	23.5 M
ViT-S/16	10^{-4} / 5×10^{-4}	0.05	21.7 M

Selección sin mirar la prueba

La mejor época de cada corrida y el modelo final se eligen por **macro-F1 de validación**. La prueba se evalúa **una sola vez**, al final.

Reproducible

Semillas fijadas (0, 1, 2; partición con 42). Cada tabla y figura del artículo se regenera con un comando del README.

Diseño experimental: 6 modelos × 3 semillas = 18 corridas

MODELO	TIPO	PARA QUÉ ESTÁ
Random Forest (color + HOG + LBP)	Clásico	Línea base 1: sin aprendizaje profundo
CNN pequeña (desde cero)	CNN simple	Línea base 2: la red más simple
ResNet-50 preentrenada	**CNN profunda**	**Comparación principal**
ViT-S/16 preentrenado	**Transformer**	**Comparación principal**
ResNet-50 desde cero	CNN profunda	Ablación: efecto del preentrenamiento
ViT-S/16 desde cero	Transformer	Ablación: efecto del preentrenamiento

Mismas particiones, mismas épocas y mismos hiperparámetros; en la ablación solo cambia el preentrenamiento (y la tasa de aprendizaje).

Métricas

Macro-F1 (principal: da el mismo peso a cada clase), exactitud balanceada y exactitud. Reportamos **media ± DE** sobre 3 semillas.

Prueba estadística

McNemar exacto, ResNet vs. ViT con la misma semilla: cuenta las fotos que solo acierta uno u otro modelo.

$$b \sim \text{Binomial}\left(b + c, \tfrac{1}{2}\right)$$

Resultados en prueba (453 fotos nunca vistas)

MODELO	MACRO-F1	EXACT. BAL.	EXACTITUD
Random Forest	0.464 ± 0.021	0.452 ± 0.014	0.558 ± 0.010
CNN pequeña (cero)	0.614 ± 0.011	0.661 ± 0.004	0.630 ± 0.009
ResNet-50 (cero)	0.642 ± 0.007	0.687 ± 0.013	0.659 ± 0.003
ViT-S/16 (cero)	0.499 ± 0.028	0.550 ± 0.019	0.497 ± 0.029
ResNet-50 (preentrenada)	0.843 ± 0.012	0.845 ± 0.011	0.855 ± 0.005
ViT-S/16 (preentrenado)	**0.853 ± 0.013**	**0.849 ± 0.008**	**0.869 ± 0.016**
ResNet-50 · Shabrina 2024	—	—	*0.682*
EfficientNetV2-B3 · Shabrina 2024	—	—	*0.736*

Media ± DE sobre 3 semillas. En cursiva, lo publicado: partición 90/10 sin deduplicar y 1 corrida, así que la comparación es solo orientativa.

0.853

macro-F1 del ViT-S/16 preentrenado: el mejor promedio

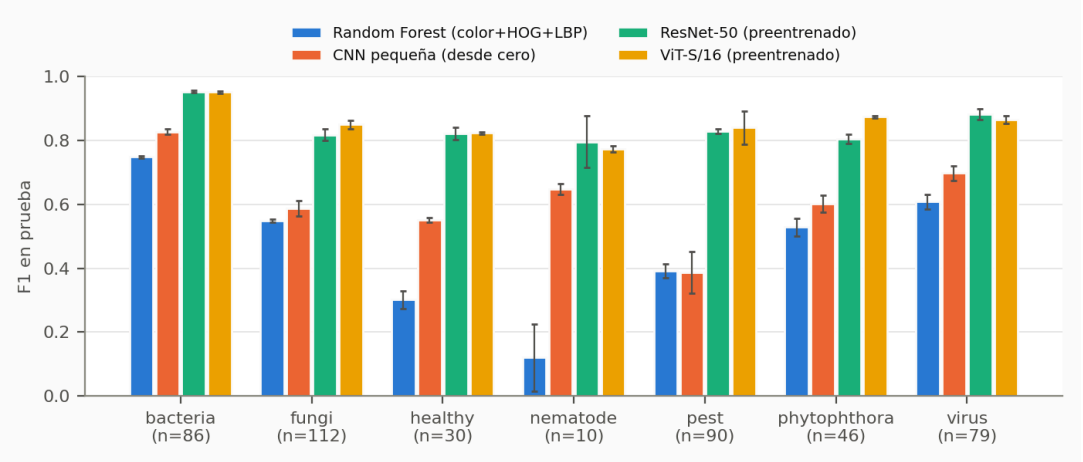
+0.39

del ViT preentrenado sobre el Random Forest; +0.24 sobre la CNN pequeña

Variabilidad baja

Los preentrenados varían ≤ 0.013 entre semillas: el resultado no depende de la suerte.

CNN frente a ViT: sin diferencia significativa



F1 por clase en prueba (media y DE, 3 semillas). Los preentrenados dominan en todas las clases.

SEMILLA	SOLO RESNET	SOLO VIT	P
0	20	27	0.38
1	24	25	1.00
2	20	31	0.16

Ninguna p < 0.05

El ViT supera a la ResNet por solo **0.010**, menos que la variación entre semillas. No prueba que sean equivalentes, pero con estos datos **la arquitectura pesa poco**.

Se reparten las clases

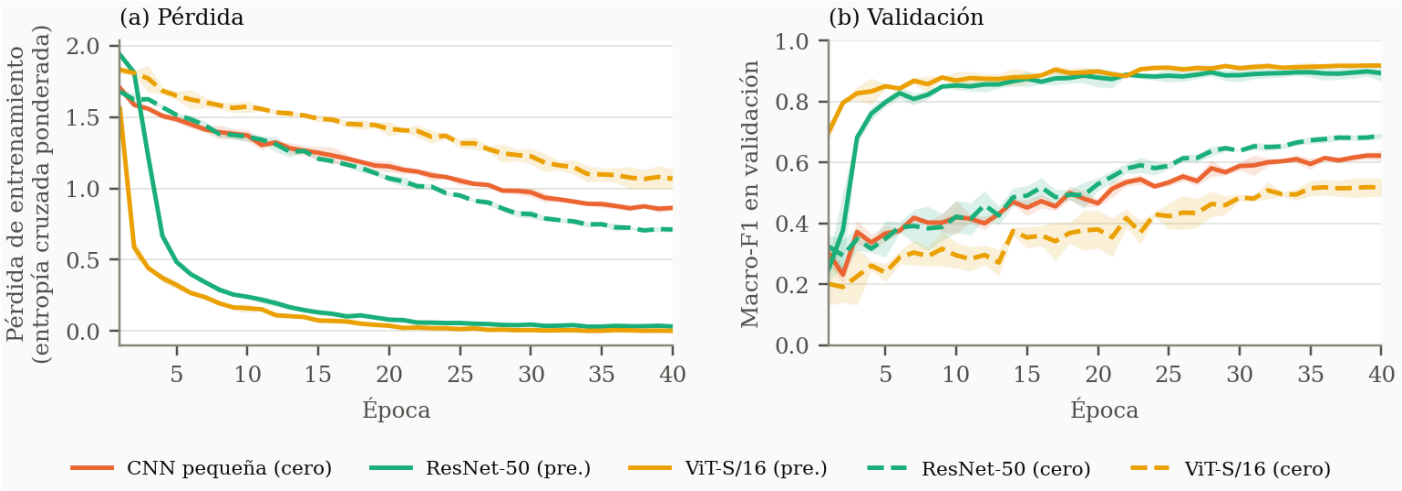
ViT gana en *Phytophthora* (0.87 vs. 0.80) y hongos; ResNet en virus (0.88 vs. 0.86) y nematodos.

Ablación: el preentrenamiento decide, sobre todo en el ViT

+0.355
macro-F1 que gana el ViT con preentrenamiento (0.499 → 0.853)

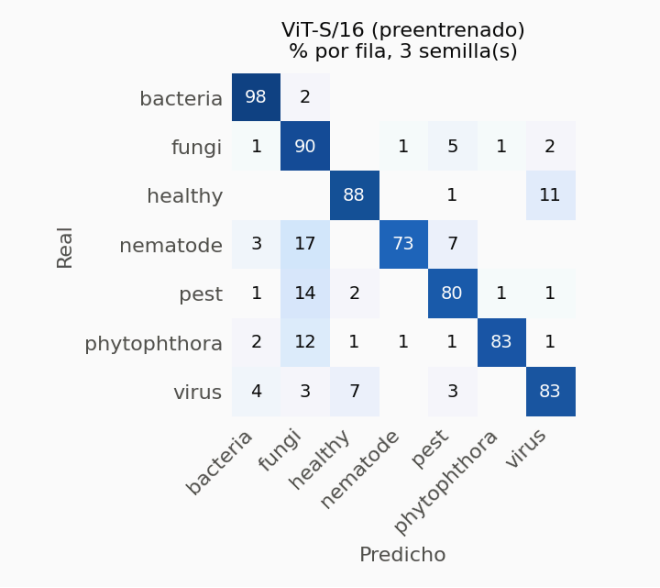
+0.201
macro-F1 que gana la ResNet (0.642 → 0.843)

0.499
ViT desde cero: **peor** que la CNN pequeña (0.614), con 18× más parámetros



Línea continua: preentrenado (y CNN pequeña); discontinua: desde cero. Los preentrenados pasan 0.8 en menos de 5 épocas. Los entrenados desde cero **seguían mejorando** a las 40 épocas: la ablación compara con el mismo presupuesto de cómputo.

¿En qué se equivoca? Todo cae en “hongos”



14 %
de las fotos de plaga → hongos (ResNet: 11 %)

12 %
Phytophthora → hongos

17 %
nematodos → hongos (solo 10 fotos)

Hongos, la “clase sumidero”

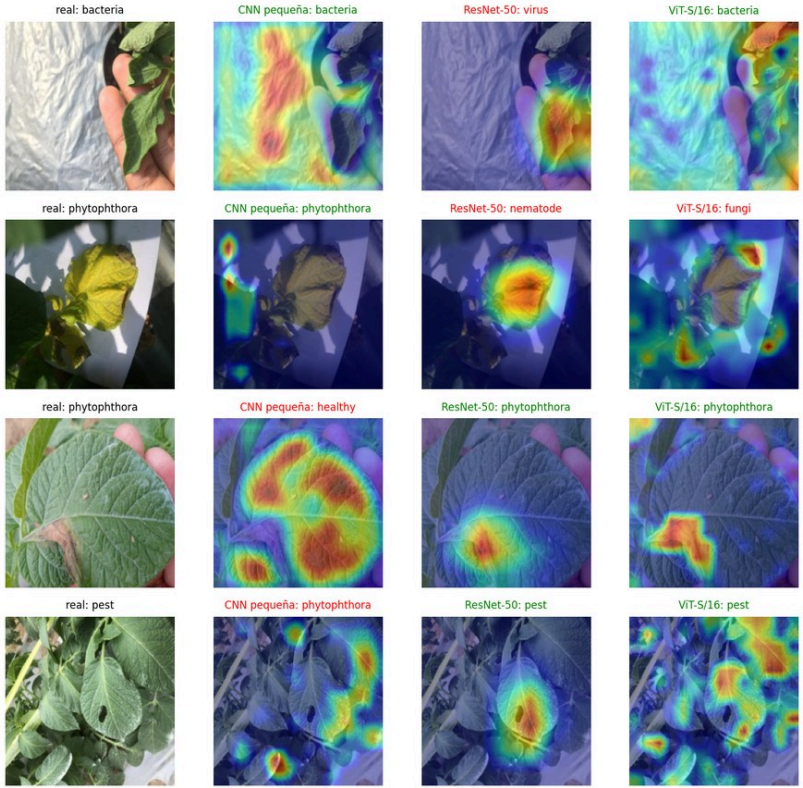
Es la clase más numerosa y la de síntomas más variados (manchas necróticas, clorosis): cuando el modelo duda, elige hongos. En el Random Forest, el 34 % de las fotos de plaga se va a hongos.

El propio dataset los confunde

De los 6 pares de fotos idénticas con dos etiquetas, **5 involucran a plaga** y 3 son exactamente **hongos / plaga**: la frontera es ambigua incluso para quienes etiquetaron.

También: el 11 % de las hojas sanas se confunde con virus, cuyo mosaico temprano es sutil a 224×224.

Grad-CAM: ¿dónde mira cada modelo?



$$\alpha_k^c = \frac{1}{Z}\sum_{i,j}\frac{\partial y^c}{\partial A_{ij}^k}, \qquad L^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

MODELO	MASA TOP-10 %	MASA CENTRAL
CNN pequeña	0.37 ± 0.18	0.34 ± 0.13
ResNet-50	**0.50 ± 0.11**	**0.61 ± 0.18**
ViT-S/16	0.29 ± 0.11	0.27 ± 0.11
Mapa uniforme	*0.10*	*0.25*

ResNet concentrada; ViT disperso

La ResNet marca la mancha (fila 3: *Phytophthora*). El ViT reparte el mapa, coherente con su atención global; Grad-CAM es menos fiel en Transformers.

CNN pequeña: atajos del fondo

Acierta “bacteria” mirando el **plástico de cobertura**, no la hoja (fila 1).

Costo computacional y hardware

≈ 5.9 h
de GPU en total: las 15 corridas de redes neuronales

~15 min
por corrida de ResNet o ViT en una Tesla T4 (Colab)

40 min
por corrida de la CNN pequeña en la laptop (GTX 1650 Ti, 4 GB)

MODELO	HARDWARE	MIN / CORRIDA	CORRIDAS
Random Forest	CPU	1.8	3
CNN pequeña	GTX 1650 Ti	40.1	3
ResNet-50 (pre)	GTX 1650 Ti / T4	65.9 / 15.8	1 / 2
ResNet-50 (cero)	T4	15.9	3
ViT-S/16 (pre)	T4	14.4	3
ViT-S/16 (cero)	T4	15.0	3

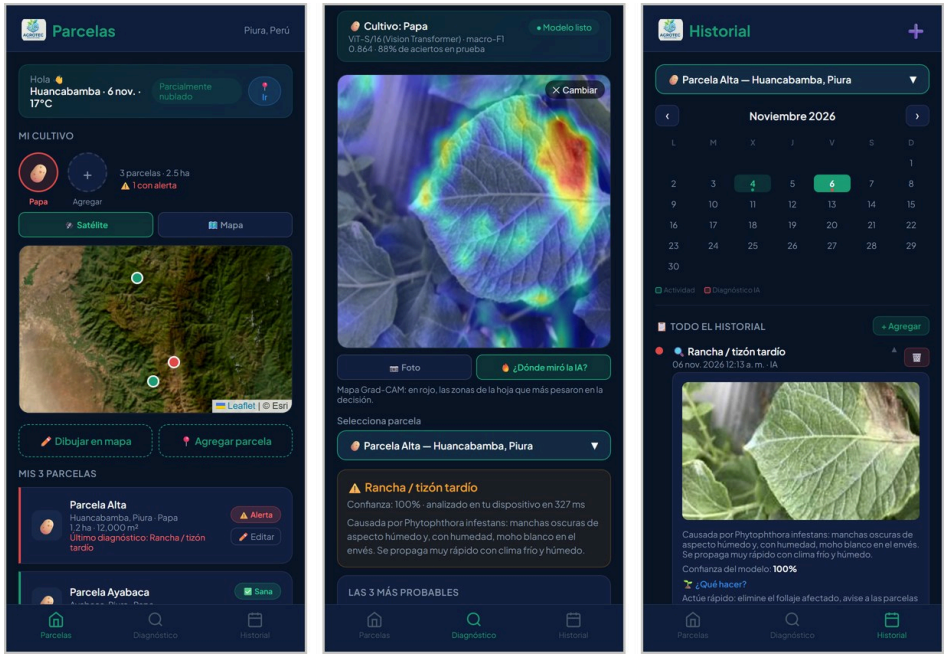
Incidente en la laptop

En la GTX 1650 Ti, la precisión mixta (fp16) hizo colapsar la validación a una sola clase. La CNN pequeña entrena en fp32 y una semilla de la ResNet se repitió en la T4. Está declarado en el artículo.

Reproducible en Colab

Todo el entrenamiento principal cabe en una T4 gratuita; los pesos están publicados para no reentrenar.

Modelo final en una app web para el celular



Parcelas en mapa satelital · diagnóstico con Grad-CAM · historial. Interfaz basada en AGROTEC, un prototipo de uno de los autores.

0.864
macro-F1 en prueba · ViT-S/16, semilla 2

88.3 %
exactitud en prueba

Elegido sin mirar la prueba

Mayor macro-F1 de **validación** (0.929) entre las 18 corridas.

Corre en el navegador, sin servidor

ONNX cuantizado a int8: **89 → 24 MB**, misma macro-F1. La foto no sale del dispositivo; ~0.5 s por diagnóstico. Grad-CAM con el gradiente escrito dentro del grafo.

agrotec-papa.vercel.app

Muestra la clase, la confianza, las 3 más probables, el Grad-CAM y un **aviso si la confianza es menor de 60 %**.

Discusión: limitaciones, sesgos y uso responsable

¿Por qué gana el preentrenamiento y no la arquitectura?

Con 2,112 fotos, lo aprendido en ImageNet (bordes, texturas, partes de objetos) vale más que el sesgo de cada arquitectura. Ese sesgo solo importa sin preentrenamiento: la convolución aporta localidad “gratis”, por eso la ResNet desde cero resiste mejor que el ViT.

Limitaciones y sesgos

- **Geográfica:** todas las fotos son de Indonesia; no sabemos cómo rinde con papa andina.
- **Clases pequeñas:** nematodos tiene 10 fotos de prueba; su F1 es incierto.
- **Brecha validación–prueba:** 0.929 → 0.864, por elegir con validación.
- **Etiquetas:** el dataset trae fotos con dos clases.

Uso responsable

- Es una herramienta de **apoyo**: no reemplaza al agrónomo.
- Un error puede llevar a un fungicida innecesario o a no tratar una plaga a tiempo.
- Por eso mostramos la confianza, el Grad-CAM y un aviso si es baja.
- Antes de usarlo en el Perú hay que validarlo con fotos locales.

Impacto

- Diagnóstico en segundos, desde un celular, **sin servidor y sin costo** por consulta.
- La foto no sale del dispositivo: protege los datos del agricultor.
- El método (auditoría, ablación, Grad-CAM) se puede repetir con fotos peruanas.

Conclusiones y trabajo futuro

01 Con preentrenamiento, **ResNet-50 y ViT-S/16 no muestran diferencia significativa** (macro-F1 0.843 y 0.853) y superan con amplitud a las líneas base.

02 Con pocos datos, **el preentrenamiento importa más que la arquitectura**: +0.355 en el ViT, +0.201 en la ResNet.

03 Auditar el dataset fue clave: había duplicados con etiquetas contradictorias que habrían inflado el resultado.

04 Grad-CAM muestra que la ResNet mira la lesión y que una red pequeña puede apoyarse en **atajos del fondo**.

05 El modelo final corre en el celular: **macro-F1 0.864 y 88.3 %** de exactitud en prueba.

Trabajo futuro

- Recolectar fotos de papa peruana y medir la transferencia de dominio.
- Probar explicaciones propias de Transformers.
- Más épocas para los modelos desde cero.
- Funcionamiento sin internet en la app.

Gracias.

Código, datos y pesos: github.com/gabo2607/papa-cnn-vs-vit
App: agrotec-papa.vercel.app